



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

دانشکده ریاضی و علوم کامپیوتر

پروژه دوم درس داده کاوی
پیاده سازی مدل های یادگیری ماشین

استاد درس: دکتر فاطمه شاکری

بهار ۱۴۰۵



هدف پروژه

هدف این پروژه، پیاده‌سازی کامل و گام‌به‌گام یک پروژه یادگیری ماشین بر روی داده‌های جدولی از صفر است. ما این بستر را به گونه‌ای طراحی کرده‌ایم تا شما به صورت کاملاً عملی، مراحل پیش‌پردازش داده‌ها را انجام دهید و تأثیر مستقیم تغییرات اعمال‌شده را بر روی عملکرد نهایی مدل مشاهده کنید. در این پروژه، با جزئیات پیاده‌سازی الگوریتم‌های یادگیری ماشین آشنا می‌شوید و یاد می‌گیرید که به جای نگاه سطحی به مدل‌ها، خروجی‌ها را به صورت تحلیلی بررسی کنید. هدف نهایی این است که بتوانید فرآیند آموزش مدل‌ها را به شکلی بهینه طراحی کرده و با نگاهی تخصصی، رفتار الگوریتم‌ها را در مواجهه با داده‌های گوناگون تحلیل نمایید.

موضوع پروژه

در این پروژه، داده‌های مربوط به درخواست‌های وام بانکی را پردازش کرده و مدلی پیش‌بینی‌کننده برای تصمیم‌گیری تخصیص یا عدم تخصیص وام طراحی و پیاده‌سازی می‌کنید. شما با یک مسئله طبقه‌بندی واقعی در حوزه بانکی مواجه‌اید و فرآیند کامل آن را از مرحله پردازش داده‌های خام تا ارزیابی نهایی مدل طی خواهید کرد. بخش مهمی از کار نیز به تحلیل نتایج اختصاص دارد تا مشخص شود کدام ویژگی‌ها و چه اقداماتی در پیش‌پردازش، بیشترین تأثیر را بر عملکرد نهایی مدل دارند.

معرفی و شرح دیتاست

دیتاست مورد استفاده در این پروژه، مجموعه‌ای از سوابق مالی و اطلاعات شخصی است که به منظور تعیین صلاحیت متقاضیان برای دریافت وام بانکی جمع‌آوری شده است. این دیتاست، شامل ویژگی‌های متنوعی است که در فرآیند تصمیم‌گیری برای تخصیص یا عدم تخصیص وام نقشی کلیدی دارند. ویژگی‌های کلیدی این مجموعه داده شامل موارد زیر است:

– **no_of_dependents**: تعداد افراد تحت تکفل متقاضی.

– **education**: سطح تحصیلات متقاضی.

– **self_employed**: وضعیت اشتغال (خوداشتغال بودن یا نبودن).

– **income_annum**: درآمد سالانه متقاضی.

– **loan_amount**: مبلغ وام درخواستی.



– `loan_term`: مدت زمان بازپرداخت وام به سال.

– `cibil_score`: امتیاز اعتباری متقاضی (`CIBIL Score`) که نقش حیاتی در ارزیابی ریسک دارد.

– `residential_assets_value` و `commercial_assets_value`: ارزش دارایی های مسکونی و تجاری متقاضی.

در این پروژه، شما باید با تحلیل این متغیرها و درک روابط میان آنها و ستون هدف (`loan_status`)، مدل های پیش بینی گر خود را توسعه دهید. هدف این است که یاد بگیرید چگونه از میان این ویژگی های مالی، الگوهایی استخراج کنید که نشان دهنده احتمال تایید یا رد درخواست وام است.

روش کار پروژه

به منظور تسهیل فرآیند یادگیری و اجرای مرحله به مرحله پروژه، یک Jupyter Notebook طراحی شده است که به عنوان راهنمای عملیاتی عمل می کند. در این نوت بوک، تمامی مراحل پروژه به صورت سلول به سلول شرح داده شده است تا شما با جزئیات اجرایی هر بخش آشنا شوید. ساختار این نوت بوک به گونه ای تدوین شده است که هدایت پروژه را در مسیرهایی نظیر درک و کاوش داده ها، پیش پردازش، آموزش و بهینه سازی مدل و تحلیل نتایج بر عهده دارد. انتظار می رود با اجرای گام به گام کدهای موجود در این نوت بوک، علاوه بر فراگیری مهارت های پیاده سازی، منطق حاکم بر هر تصمیم در پروژه های داده کاوی را به طور دقیق درک کنید.

جزئیات پیاده سازی

در نوت بوک آموزشی پروژه، تمامی مراحل پیاده سازی به صورت گام به گام با جزئیات فنی زیر مورد بررسی قرار گرفته است:

– بارگذاری مجموعه داده

– تحلیل اکتشافی داده ها به صورت آماری: حذف داده های اضافی، پردازش مقادیر گمشده

– تحلیل اکتشافی داده ها به صورت بصری: هیستوگرام توزیع ویژگی های عددی، نمودار تعادل کلاس ها، ماتریس همبستگی ویژگی های عددی، نمودارهای جعبه ای ویژگی های عددی

– عددی سازی ویژگی های دسته ای: روش `one hot encoding` و `ordinal encoding`

– حذف داده های پرت



- انتخاب ویژگی: معیارهای ضریب پیرسن و اطلاعات متقابل
- تقسیم داده به مجموعه آموزش و تست
- متعادل سازی کلاس ها: روش های random oversampling, random undersampling و SMOTE
- استاندارد سازی و نرمال سازی داده ها: نرمال سازی MIN MAX و استاندارد سازی Z-Score
- مدل ها: رگرسیون لاجیستیک، درخت تصمیم، جنگل تصادفی، نزدیک ترین همسایه، ماشین بردار پشتیبان، گرادینت تقویت شده
- اعتبار سنجی متقابل و بهینه سازی هایپر پارامترها: روش k-fold validation و grid search
- بررسی نتایج شامل مقایسه نمودارها و معیارهای ارزیابی و سوالات تحلیلی

مهلت ارسال

شما برای ارسال این پروژه تا پایان ساعت ۲۳:۵۹ روز دوشنبه ۱۸ خرداد فرصت دارید.

نحوه ارسال

فایل ارسالی شما باید به قالب ipynb. با نام گذاری GroupID_P2.ipynb باشد که در آن می بایست به جای GroupID، شماره گروه خود را قرار دهید. برای نوشتن توضیحات فارسی در نوت بوک، حتماً از قالب سلول های متنی از پیش قرار داده شده استفاده کنید و در صورت نیاز، برای فرمت دهی مناسب به متن از تگ های HTML و دستورات LaTeX استفاده کنید.

ارتباط با تدریس یاران

در صورت بروز هرگونه ابهام یا سوال در طول انجام پروژه، می توانید از طریق پیام رسان به تدریس یاران زیر در ارتباط باشید:

- روزان واصف

- رها کریمی نیا

- محدثه مقدم